Emna borji DSB

Rapport d’Analyse Prédictive de l’Attrition Digitale Bancaire

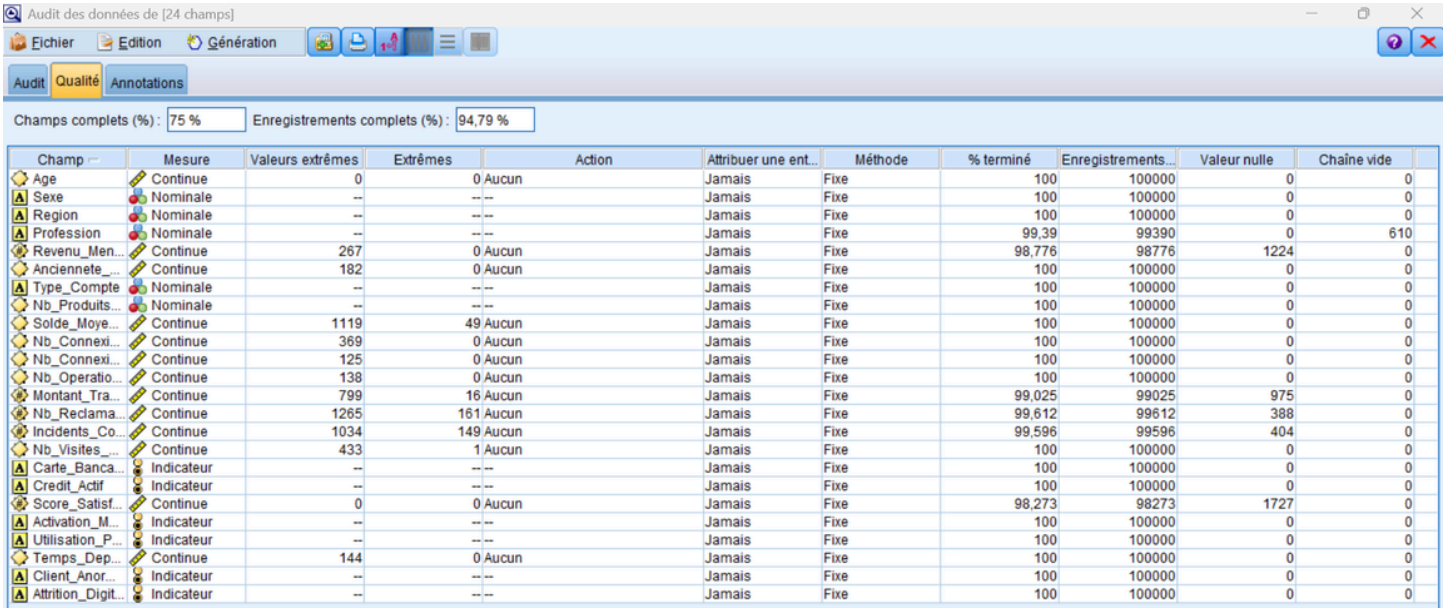
PARTIE 1 : AUDIT ET QUALITÉ DU DATASET

1. Qualité globale du dataset

L’analyse exploratoire du jeu de données montre une qualité globalement satisfaisante. Le dataset contient 100 000 observations structurées et cohérentes, ce qui le rend adapté à des techniques de modélisation prédictive.

La majorité des variables présentent un taux de complétude élevé, ce qui garantit une base fiable pour les analyses statistiques et les modèles de data mining.

2. Analyse des valeurs manquantes



Champ	Mesure	Valeurs extrêmes	Extrêmes	Action	Attribuer une ent...	Méthode	% terminé	Enregistrements...	Valeur nulle	Chaîne vide
Age	Continue	0	0	Aucun	Jamais	Fixe	100	100000	0	0
Sexe	Nominale	--	--	--	Jamais	Fixe	100	100000	0	0
Region	Nominale	--	--	--	Jamais	Fixe	100	100000	0	0
Profession	Nominale	--	--	--	Jamais	Fixe	99,39	99390	0	610
Revenu_Men...	Continue	267	0	Aucun	Jamais	Fixe	98,776	98776	1224	0
Anciennete_...	Continue	182	0	Aucun	Jamais	Fixe	100	100000	0	0
Type_Compte	Nominale	--	--	--	Jamais	Fixe	100	100000	0	0
Nb_Produits...	Nominale	--	--	--	Jamais	Fixe	100	100000	0	0
Solde_Moye...	Continue	1119	49	Aucun	Jamais	Fixe	100	100000	0	0
Nb_Connexi...	Continue	369	0	Aucun	Jamais	Fixe	100	100000	0	0
Nb_Connexi...	Continue	125	0	Aucun	Jamais	Fixe	100	100000	0	0
Nb_Operatio...	Continue	138	0	Aucun	Jamais	Fixe	100	100000	0	0
Montant_Tra...	Continue	799	16	Aucun	Jamais	Fixe	99,025	99025	975	0
Nb_Reclama...	Continue	1265	161	Aucun	Jamais	Fixe	99,612	99612	388	0
Incidents_Co...	Continue	1034	149	Aucun	Jamais	Fixe	99,596	99596	404	0
Nb_Visites_...	Continue	433	1	Aucun	Jamais	Fixe	100	100000	0	0
Carte_Banca...	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0
Credit_Actif	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0
Score_Satisf...	Continue	0	0	Aucun	Jamais	Fixe	98,273	98273	1727	0
Activation_M...	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0
Utilisation_P...	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0
Temps_Dep...	Continue	144	0	Aucun	Jamais	Fixe	100	100000	0	0
Client_Anor...	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0
Attrition_Digit...	Indicateur	--	--	--	Jamais	Fixe	100	100000	0	0

Des valeurs manquantes sont observées sur certaines variables du dataset :

- Revenu_Mensuel_TND : 1 224 valeurs manquantes (1,22 %)
- Montant_Transactions_Digitales_TND : 975 valeurs manquantes (0,98 %)
- Score_Satisfaction : 1 727 valeurs manquantes (1,73 %)
- Nb_Reclamations et Incidents_Connexion : quelques valeurs manquantes marginales

Bien que le taux global de valeurs manquantes soit faible, ces absences concernent des variables importantes pour l’analyse du comportement client et de l’attrition.

Ces données devront donc être traitées lors de la phase de préparation afin de limiter les biais dans les modèles prédictifs.

3. Incohérences et anomalies

Certaines incohérences ont été identifiées dans le dataset :

- Les variables de type indicateur (Oui/Non) sont correctement structurées mais nécessitent un encodage binaire pour la modélisation.
- Des valeurs manquantes apparaissent dans des variables comportementales telles que les incidents de connexion et les réclamations.

Ces éléments peuvent introduire des biais si ils ne sont pas traités avant la modélisation.

4. Analyse des variables de type professionnel

Une analyse spécifique de la variable Profession met en évidence 610 valeurs non renseignées.

Ces valeurs ne sont pas explicitement codées comme manquantes mais apparaissent sous forme de catégorie distincte dans la distribution.

Cela peut s'expliquer par :

- une absence de déclaration de la profession par certains clients
- un défaut de collecte de l'information lors de l'enregistrement des données

Cette situation nécessite un traitement adapté afin d'éviter une mauvaise interprétation de cette variable dans les analyses.

5. Variables constantes ou peu informatives

Certaines variables présentent une faible variabilité et un pouvoir discriminant limité.

On observe notamment :

- des variables fortement déséquilibrées avec une modalité dominante
- des variables quasi constantes sur une grande partie des observations

Ces variables apportent peu d'information utile pour la modélisation et peuvent être considérées comme peu contributives dans les modèles prédictifs.

6. Synthèse générale

L'audit du dataset permet de tirer les conclusions suivantes :

- Le dataset est globalement propre et exploitable pour la modélisation
- Les valeurs manquantes restent limitées mais concernent des variables importantes
- La structure des données est cohérente et adaptée à une analyse prédictive

- Certaines variables nécessitent toutefois un traitement préalable avant la modélisation

Dans l'ensemble, la base de données constitue un support fiable pour les étapes de préparation, de transformation et de modélisation.

PARTIE 2 : ANALYSE DES VALEURS EXTRÊMES (OUTLIERS)

1. Méthodologie de détection

La détection des valeurs extrêmes a été réalisée à l'aide de **Data Audit**.

L'analyse repose sur l'étude des distributions statistiques des variables quantitatives ainsi que sur l'utilisation des indicateurs suivants :

- l'asymétrie (skewness)
- la kurtosis

Ces indicateurs permettent d'identifier les variables présentant des distributions fortement déséquilibrées et susceptibles de contenir des valeurs extrêmes.

2. Variables concernées

Les valeurs extrêmes ont été identifiées sur plusieurs variables du dataset :

- Revenu_Mensuel_TND
- Solde_Moyen_TND
- Montant_Transactions_Digitales_TND
- Nb_Reclamations
- Incidents_Connexion
- Temps_Depuis_Derniere_Connexion_Jours

Ces variables présentent une forte dispersion ainsi qu'une distribution asymétrique.

3. Analyse statistique

L'analyse des distributions met en évidence plusieurs caractéristiques :

- Une asymétrie positive importante sur les variables de revenu et de transactions, indiquant la présence de clients à très forte activité financière.
- Une kurtosis élevée sur les variables liées aux réclamations et aux incidents, traduisant la présence de valeurs rares mais extrêmes.
- Un écart notable entre la moyenne et la médiane pour plusieurs variables, confirmant l'influence des valeurs atypiques sur les distributions.

Ces résultats indiquent que les variables étudiées ne suivent pas une distribution normale et sont fortement influencées par des observations extrêmes.

4. Interprétation métier

Les valeurs extrêmes identifiées ne correspondent pas nécessairement à des erreurs de saisie. Elles traduisent plutôt l'hétérogénéité de la clientèle bancaire.

On distingue plusieurs profils :

- des clients à forte valeur caractérisés par des revenus et des transactions élevés,
- des clients à faible activité ou peu engagés,
- des clients présentant des comportements atypiques liés à des niveaux élevés de réclamations ou d'incidents.

Dans un contexte bancaire, ces profils sont importants car ils reflètent la diversité des comportements clients et influencent directement les analyses de risque et d'attrition.

5. Traitement des valeurs extrêmes

Afin de limiter l'impact des valeurs extrêmes sur les modèles prédictifs tout en conservant l'information, une méthode de traitement a été appliquée dans SPSS Modeler.

Cette méthode consiste en un **ajustement des valeurs extrêmes (capping)**, permettant de :

- réduire l'influence des observations atypiques,
- maintenir la structure globale des données,
- améliorer la robustesse des modèles.

Cette approche permet de conserver les tendances générales tout en limitant les distorsions statistiques.

6. Conclusion

Les valeurs extrêmes constituent une caractéristique importante du dataset étudié.

Elles reflètent la diversité des comportements clients et doivent être prises en compte dans la phase de modélisation.

Le traitement appliqué permet de réduire leur impact sans suppression d'information pertinente, garantissant ainsi une meilleure qualité des données pour les analyses prédictives.

PARTIE 3 : NETTOYAGE, TRANSFORMATION ET ENRICHISSEMENT DES DONNÉES

1. Vérification des doublons

Une vérification des doublons a été effectuée à l'aide du nœud **Distinct** dans SPSS Modeler, en s'appuyant sur l'identifiant unique **Client_ID**.

Les résultats montrent qu'aucun doublon n'a été détecté dans le dataset. Le nombre d'observations est resté inchangé après traitement.

Cette absence de doublons garantit l'unicité des enregistrements et la fiabilité des analyses ultérieures.

2. Création de variables dérivées

Afin d'améliorer la capacité explicative du modèle et de synthétiser les comportements clients, plusieurs variables dérivées ont été créées.

Ces variables permettent de regrouper plusieurs indicateurs en scores globaux représentatifs des dimensions clés du comportement client.

2.1 Score d'engagement digital

Cette variable mesure le niveau d'activité digitale du client.

Formule :
Score_Engagement_Digital = Nb_Connexions_Web + Nb_Connexions_Mobile + Nb_Operations_Online

Cette variable permet d'évaluer l'intensité d'utilisation des canaux digitaux par le client.

2.2 Score de problèmes

Cette variable mesure les difficultés rencontrées par le client.

Formule :
Score_Problemes = Nb_Reclamations + Incidents_Connexion

Elle permet d'identifier les clients confrontés à des problèmes techniques ou relationnels.

2.3 Intensité digitale

Cette variable mesure la valeur moyenne générée par opération digitale.

Formule :
Intensite_Digitale = Montant_Transactions_Digitales_TND / (Nb_Operations_Online + 1)

Elle permet d'évaluer l'efficacité de l'usage des services digitaux.

2.4 Score de relation bancaire

Cette variable mesure la solidité de la relation entre le client et la banque.

Formule :
Score_Relation_Banque = Nb_Produits_Bancaires + Anciennete_Bancaire_Annees

Elle reflète le niveau de fidélité et d'ancrage du client dans la banque.

3. Recodage des variables en classes

Afin de faciliter l'interprétation des données et leur utilisation dans les modèles, plusieurs variables ont été transformées en variables catégorielles ordinales.

3.1 Score d'engagement digital

Cette variable a été regroupée en trois niveaux :

- faible engagement
- engagement moyen
- fort engagement

Cette transformation permet d'identifier rapidement les profils d'utilisation digitale.

3.2 Score de problèmes

Cette variable a été recodée en trois classes :

- faible niveau de problèmes
- niveau moyen
- niveau élevé

Elle permet de distinguer les clients selon leur expérience négative avec la banque.

3.3 Intensité digitale

Cette variable a été transformée en classes :

- faible intensité
- intensité moyenne
- forte intensité

Elle permet d'identifier les profils de valeur générée par usage digital.

3.4 Score de relation bancaire

Cette variable a été recodée en niveaux :

- relation faible
- relation moyenne
- relation forte

Elle permet d’évaluer la profondeur de la relation client-banque.

4. Discrétisation des variables continues

Dans un objectif de simplification et d’amélioration de l’interprétation, plusieurs variables continues ont été transformées en classes.

4.1 Âge

La variable âge a été segmentée en trois catégories :

- jeunes clients : 18 à 35 ans
- clients adultes : 35 à 45 ans
- clients seniors : 45 à 72 ans

Cette segmentation permet une analyse démographique structurée.

4.2 Revenu mensuel

La variable revenu mensuel a été divisée en trois niveaux :

- revenus faibles
- revenus moyens
- revenus élevés

Cette classification permet d’analyser la capacité financière des clients.

4.3 Score de satisfaction

La variable de satisfaction a été transformée en trois niveaux :

- faible satisfaction
- satisfaction moyenne
- forte satisfaction

Elle permet de simplifier l’analyse du ressenti client.

5. Conclusion de la transformation des données

Les transformations réalisées permettent de structurer le dataset de manière plus exploitable pour les étapes de modélisation.

Elles contribuent à :

- améliorer la lisibilité des variables
- faciliter l’interprétation métier
- réduire la complexité des données continues
- renforcer la qualité des analyses prédictives

PARTIE 4 : SÉLECTION DES VARIABLES ET RÉDUCTION DE DIMENSIONNALITÉ

1. Objectif de la sélection des variables

Cette étape vise à réduire la complexité du dataset en conservant uniquement les variables ayant un réel pouvoir explicatif sur la variable cible **Attrition_Digitale**.

L'objectif principal est de :

- limiter le bruit statistique
- éviter le surapprentissage (overfitting)
- améliorer la performance et la stabilité des modèles
- simplifier l'interprétation métier

2. Méthodologie de sélection

La sélection des variables a été réalisée à l'aide du nœud **Feature Selection** dans SPSS Modeler.

Deux types de tests ont été utilisés selon la nature des variables :

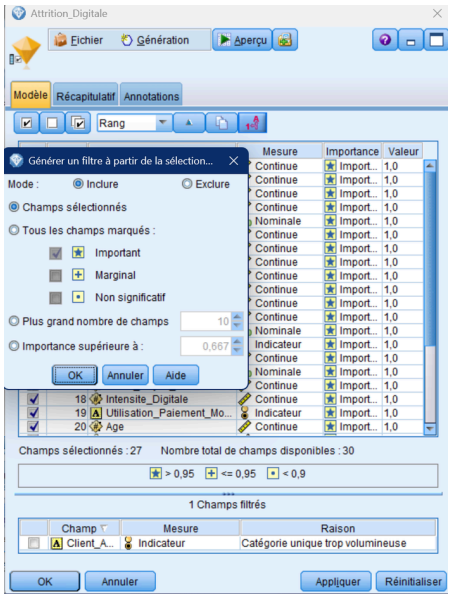
- test du Chi-deux pour les variables catégorielles
- analyse de variance (ANOVA) pour les variables continues

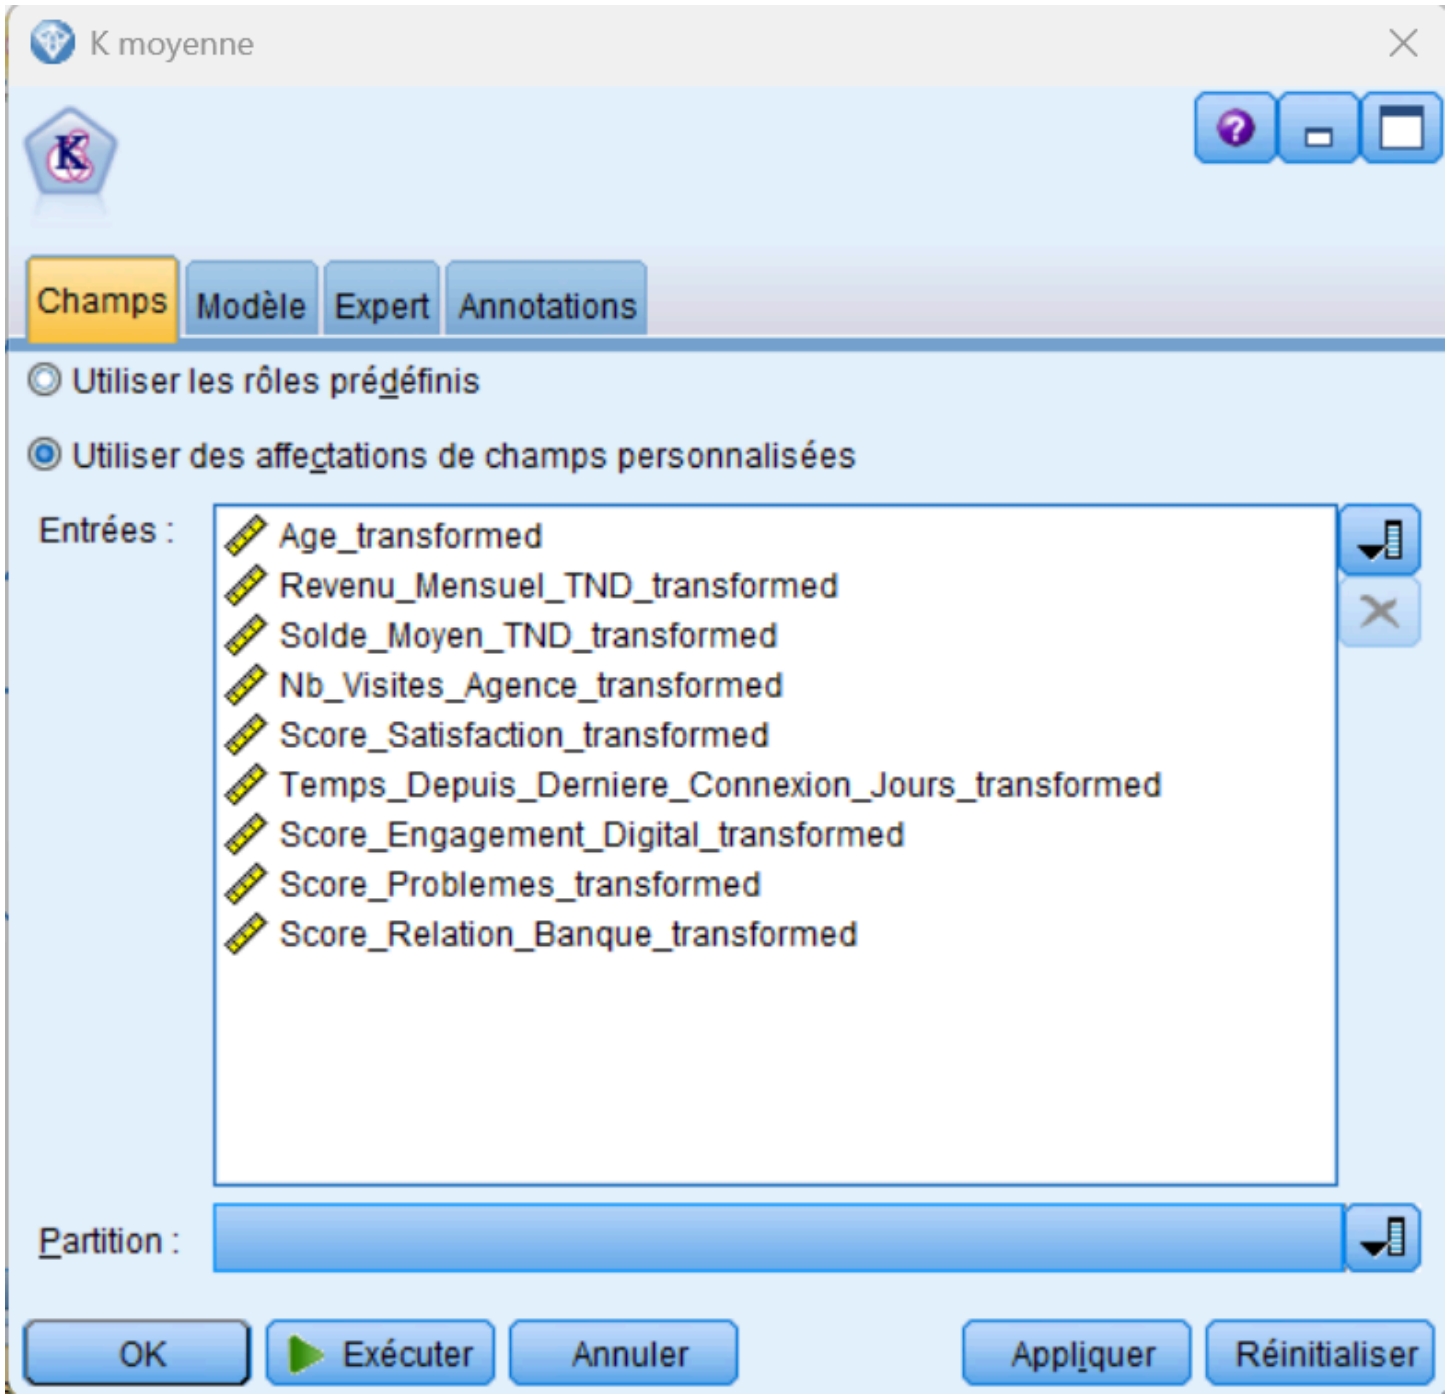
Des critères supplémentaires ont été appliqués :

- suppression des variables avec plus de 70 % de valeurs manquantes
- exclusion des variables à variance quasi nulle
- élimination des variables présentant une distribution trop uniforme

3. Résultats de la sélection

L'analyse a permis de réduire le nombre de variables initiales en ne conservant que les variables les plus significatives.


Attrition_Digitale
Fichier
Génération
Aperçu
Modèle
Récapitulatif
Annotations
Rang
Générer un filtre à partir de la sélection...
Mode :
Inclure
Exclure
Champs sélectionnés
Tous les champs marqués :
Important
Marginal
Non significatif
Plus grand nombre de champs
Importance supérieure à :
OK
Annuler
Aide
Mesure
Importance
Valeur
Intensite_Digitale
Utilisation_Paiement_Mo...
Age
Champs sélectionnés : 27
Nombre total de champs disponibles : 30
> 0,95
<= 0,95
< 0,9
1 Champs filtrés
Champ
Mesure
Raison
Client_A...
Indicateur
Catégorie unique trop volumineuse
OK
Annuler
Appliquer
Réinitialiser


K moyenne
Champs
Modèle
Expert
Annotations
Utiliser les rôles prédéfinis
Utiliser des affectations de champs personnalisées
Entrées :
Age_transformed
Revenu_Mensuel_TND_transformed
Solde_Moyen_TND_transformed
Nb_Visites_Agence_transformed
Score_Satisfaction_transformed
Temps_Depuis_Derniere_Connexion_Jours_transformed
Score_Engagement_Digital_transformed
Score_Problemes_transformed
Score_Relation_Banque_transformed
Partition :
OK
Exécuter
Annuler
Appliquer
Réinitialiser

Les variables retenues sont principalement :

- les variables liées à l'usage digital (connexions, opérations en ligne)
- les variables de qualité de service (réclamations, incidents)
- les variables comportementales synthétiques (scores dérivés)
- certaines variables discrétisées (âge, revenu, satisfaction)

Les variables jugées peu informatives ont été éliminées, notamment celles présentant une faible variabilité ou un faible lien avec la variable cible.

4. Analyse des corrélations

Une matrice de corrélation de Pearson a été utilisée afin d'identifier les relations entre variables et de détecter les redondances.

Les résultats montrent plusieurs corrélations fortes :

- Score_Satisfaction et Score_Problemes : forte corrélation négative
- Score_Engagement_Digital et Nb_Connexions : corrélation très élevée
- Score_Relation_Banque et Anciennete_Bancaire : forte corrélation positive

Ces résultats indiquent que certaines variables brutes et variables dérivées mesurent des dimensions similaires.

5. Traitement de la colinéarité

Afin d'éviter la redondance d'information, une réduction des variables colinéaires a été effectuée.

Les principes appliqués sont les suivants :

- conservation des variables synthétiques (scores) au détriment des variables brutes
- suppression des variables fortement corrélées entre elles
- maintien des variables les plus interprétables pour les modèles

Cette étape permet de stabiliser les modèles et d'améliorer leur généralisation.

6. Justification métier

La réduction de dimensionnalité est essentielle dans un contexte bancaire pour plusieurs raisons :

- amélioration de la lisibilité des résultats
- réduction du temps de calcul des modèles
- diminution du risque de surapprentissage
- meilleure compréhension des facteurs d'attrition

Elle permet également de concentrer l'analyse sur les variables ayant un impact réel sur le comportement client.

7. Conclusion

La phase de sélection et de réduction des variables a permis d'obtenir un dataset optimisé, composé uniquement de variables pertinentes et non redondantes.

Cette étape constitue une base solide pour la phase de modélisation prédictive, en garantissant à la fois performance statistique et interprétabilité métier.

PARTIE 5 : SEGMENTATION DE LA CLIENTÈLE PAR CLUSTERING

1. Objectif de la segmentation

L'objectif de cette étape est de regrouper les clients en segments homogènes selon leurs comportements, afin de mieux comprendre la structure de la clientèle et d'identifier des profils distincts.

Cette segmentation permet notamment de :

- identifier des groupes de clients aux comportements similaires ;
- adapter les stratégies marketing et de fidélisation ;
- mieux comprendre les facteurs de risque d'attrition.

2. Méthodologie utilisée

La segmentation a été réalisée à l'aide de l'algorithme **K-Means**, méthode de classification non supervisée fondée sur la proximité entre les observations.

Avant l'application de l'algorithme, les variables quantitatives ont été **normalisées par la méthode Min-Max**, afin de les ramener sur une échelle commune comprise entre 0 et 1. Cette transformation est indispensable pour éviter qu'une variable à grande amplitude, ce que les humains adorent inventer, domine artificiellement le calcul des distances.

Les variables utilisées dans le clustering correspondent donc aux versions transformées, identifiées par le suffixe **_transformed**.

Les variables retenues sont :

- Age_transformed
- Revenu_Mensuel_TND_transformed
- Nb_Produits_Bancaires_transformed
- Solde_Moyen_TND_transformed

- Score_Engagement_Digital_transformed
- Score_Relation_Banque_transformed
- Temps_Depuis_Derniere_Connexion_Jours_transformed
- Nb_Visites_Agence_transformed
- Score_Satisfaction_transformed
- Score_Problemes_transformed

Les variables identifiantes ou non numériques ont été exclues afin de garantir la cohérence du calcul des distances euclidiennes utilisé par K-Means.

3. Résultats de la segmentation

L'application de l'algorithme K-Means a permis d'identifier **trois segments principaux** de clients présentant des comportements distincts.

3.1 Cluster 1 : Les clients traditionnels de proximité

Ce segment est caractérisé par :

- une moyenne d'âge relativement élevée ;
- une fréquence importante de visites en agence ;
- un usage digital faible à modéré ;
- des revenus intermédiaires.

Ces clients restent attachés à la relation humaine avec la banque.

Le risque d'attrition y est modéré, notamment en cas de dégradation du service en agence ou de transformation trop rapide vers le digital.

3.2 Cluster 2 : Les clients premium en rupture

Ce segment présente les caractéristiques suivantes :

- revenus élevés ;
- solde moyen important ;
- fort engagement digital ;
- faible niveau de satisfaction ;
- score élevé de problèmes et de réclamations.

Il s'agit du segment le plus critique pour l'analyse de l'attrition.

Malgré leur forte valeur économique et leur usage intensif des services digitaux, ces clients présentent un risque élevé de départ en raison d'une expérience jugée insatisfaisante. Classique : les meilleurs clients exigent un bon service. Quelle extravagance.

3.3 Cluster 3 : Les clients autonomes et satisfaits

Ce segment se distingue par :

- une utilisation digitale régulière et efficace ;
- une faible fréquentation des agences ;
- un niveau élevé de satisfaction ;
- un faible score de problèmes.

Ces clients constituent une base stable et rentable pour la banque.

Le risque d'attrition y est très faible.

4. Analyse métier des segments

La segmentation met en évidence trois profils stratégiques :

- un segment à forte valeur mais fortement exposé au départ ;
- un segment stable et satisfait à fidéliser ;
- un segment intermédiaire attaché aux services physiques.

Cette lecture permet d'adapter les actions commerciales selon les besoins spécifiques de chaque groupe plutôt que d'appliquer la grande tradition humaine du traitement identique pour des cas totalement différents.

5. Conclusion

La segmentation par K-Means a permis d'identifier trois profils clients distincts à partir des variables normalisées par Min-Max.

Cette étape constitue un élément central de l'analyse, car elle relie les comportements observés aux risques potentiels d'attrition et oriente les stratégies de fidélisation.

Elle représente également une base pertinente pour le croisement avec les modèles prédictifs développés dans les étapes suivantes.

PARTIE 6 : DÉTECTION DES ANOMALIES ET ANALYSE DES PROFILS ATYPIQUES

1. Objectif de la détection d'anomalies

L'objectif de cette étape est d'identifier les clients dont le comportement s'écarte significativement de la population générale.

Contrairement aux modèles de prédiction de l'attrition, qui recherchent des comportements connus menant au départ, la détection d'anomalies vise à repérer des profils rares, inhabituels ou atypiques.

Cette analyse permet notamment de :

- détecter des comportements non standards ;
- identifier des clients nécessitant une attention particulière ;
- repérer des incohérences potentielles dans les données ;
- enrichir la connaissance client.

2. Méthodologie utilisée

La détection des anomalies a été réalisée à l'aide des outils de modélisation disponibles dans SPSS Modeler.

Les variables comportementales, financières et relationnelles les plus pertinentes ont été utilisées afin de calculer un score d'anomalie pour chaque client.

Les individus présentant les scores les plus élevés ont été considérés comme les observations les plus atypiques.

Cette approche permet d'isoler une faible proportion de clients dont les caractéristiques diffèrent fortement du comportement moyen. En général, ce sont les cas que personne ne regarde jusqu'au jour où ils deviennent un problème.

3. Résultats généraux

L'analyse a permis d'identifier environ **1 % de la base de données**, soit les clients les plus éloignés du profil moyen.

Ces observations atypiques ne représentent pas nécessairement des erreurs. Elles peuvent correspondre à :

- des clients à très forte valeur ;
- des clients fortement insatisfaits ;
- des usages bancaires inhabituels ;
- des profils mixtes difficilement classables dans les segments traditionnels.

4. Analyse de profils atypiques

	Temps_Depuis_Derniere_Connexion_Jours_transformed	Score_Engagement_Digital_transformed	Score_Problemes_transformed	Score_Relation_Banque_transformed	$O-Anomaly	$O-AnomalyIndex	$O-
1	0.159	0.536	0.400	0.654	T	2.969	
2	0.159	0.737	0.867	0.346	T	2.902	
3	0.402	0.559	0.800	0.885	T	2.861	

4.1 Profil 1 : Cadre senior fortement dépendant de l'agence

Ce profil se caractérise par :

- un âge élevé ;
- de nombreuses visites en agence ;
- un niveau patrimonial important.

Il s’agit d’un client disposant d’un fort potentiel financier, mais conservant un comportement très traditionnel.

Ce profil est atypique car les clients à revenus élevés sont généralement plus digitalisés.

4.2 Profil 2 : Client à faible revenu fortement insatisfait

Ce profil présente :

- un revenu modeste ;
- un solde faible ;
- un niveau élevé de problèmes ;
- une satisfaction très basse.

Il s’agit d’un client fragile cumulant plusieurs signaux négatifs malgré une faible valeur financière.

Ce type de profil peut révéler des difficultés opérationnelles ou une mauvaise expérience client persistante.

4.3 Profil 3 : Client à forte valeur fortement mécontent

Ce profil se distingue par :

- un solde moyen élevé ;
- une relation bancaire ancienne ;
- un score élevé de problèmes ;
- un faible niveau de satisfaction.

Il représente un cas critique, car un client rentable mais insatisfait présente un risque élevé de départ ou de transfert d’actifs vers la concurrence. Les banques aiment appeler cela “surprise”, alors que les signaux clignotent depuis des mois.

5. Intérêt métier de la détection d’anomalies

L’identification des profils atypiques présente plusieurs avantages :

- cibler les clients nécessitant un suivi personnalisé ;
- détecter précocement les situations à risque ;
- compléter la segmentation classique ;
- améliorer les dispositifs de fidélisation ;
- renforcer les contrôles internes.

Cette approche permet de traiter des cas que les modèles standards détectent parfois mal.

6. Conclusion

La détection d’anomalies a permis d’isoler les clients les plus atypiques du dataset et de mettre en évidence plusieurs profils stratégiques.

Ces observations montrent que certains clients ne peuvent être expliqués uniquement par les segments classiques ou par les modèles d’attrition.

Cette étape enrichit l’analyse globale en apportant une vision complémentaire centrée sur les cas rares à forte valeur métier.

PARTIE 7 : PARTITIONNEMENT DES DONNÉES ET ÉQUILIBRAGE DES CLASSES

1. Objectif de la préparation à la modélisation

Avant la construction des modèles prédictifs, il est nécessaire de préparer le dataset afin de garantir une évaluation fiable des performances.

Cette étape poursuit deux objectifs principaux :

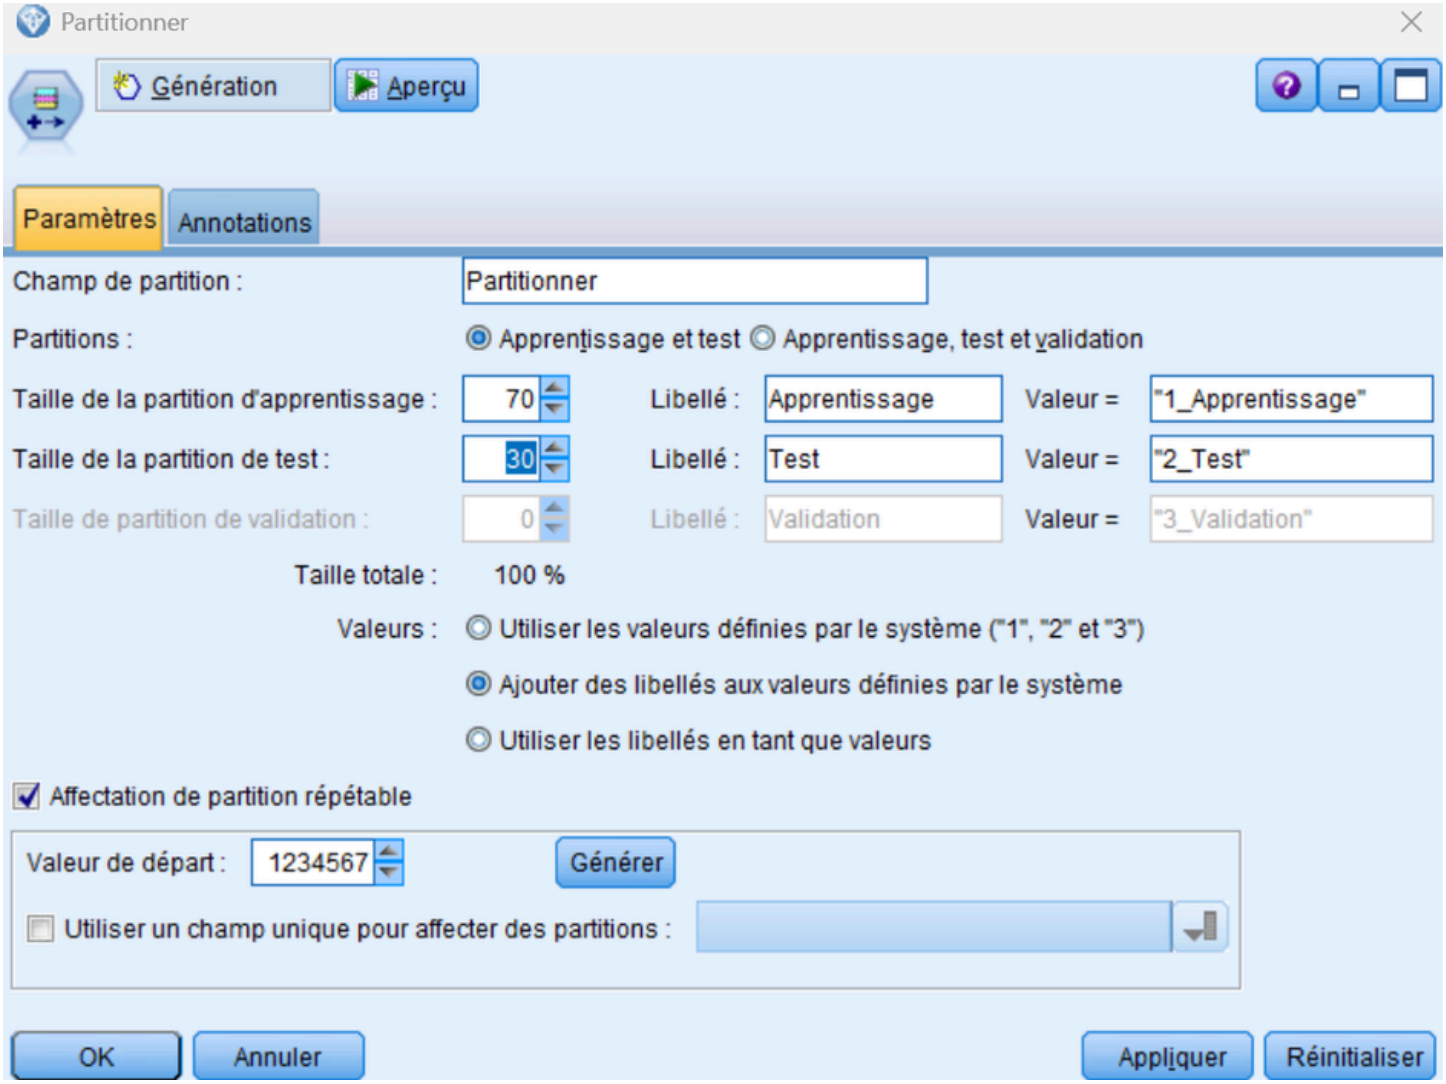
- séparer les données utilisées pour l’apprentissage de celles utilisées pour l’évaluation
- corriger le déséquilibre éventuel entre les classes de la variable cible **Attrition_Digitale**.

Sans cette rigueur méthodologique, un modèle peut sembler performant tout en étant inutile en situation réelle. Une spécialité assez répandue.

2. Partitionnement des données

Le jeu de données a été scindé en deux sous-ensembles distincts :

- **70 % des observations** pour l’apprentissage du modèle ;
- **30 % des observations** pour le test et l’évaluation finale.



Le partitionnement a été réalisé de manière aléatoire afin de garantir la représentativité des deux échantillons.

Une valeur de départ fixe (seed) a été utilisée pour assurer la reproductibilité des résultats.

L'échantillon d'apprentissage sert à entraîner les algorithmes, tandis que l'échantillon de test permet de mesurer la capacité de généralisation sur des données jamais vues auparavant.

3. Analyse du déséquilibre de la variable cible

L'étude de la variable **Attrition_Digitale** a mis en évidence une répartition déséquilibrée entre les classes :

Valeur	Proportion	%	Comptage
Non		75.38	75377
Oui		24.62	24623

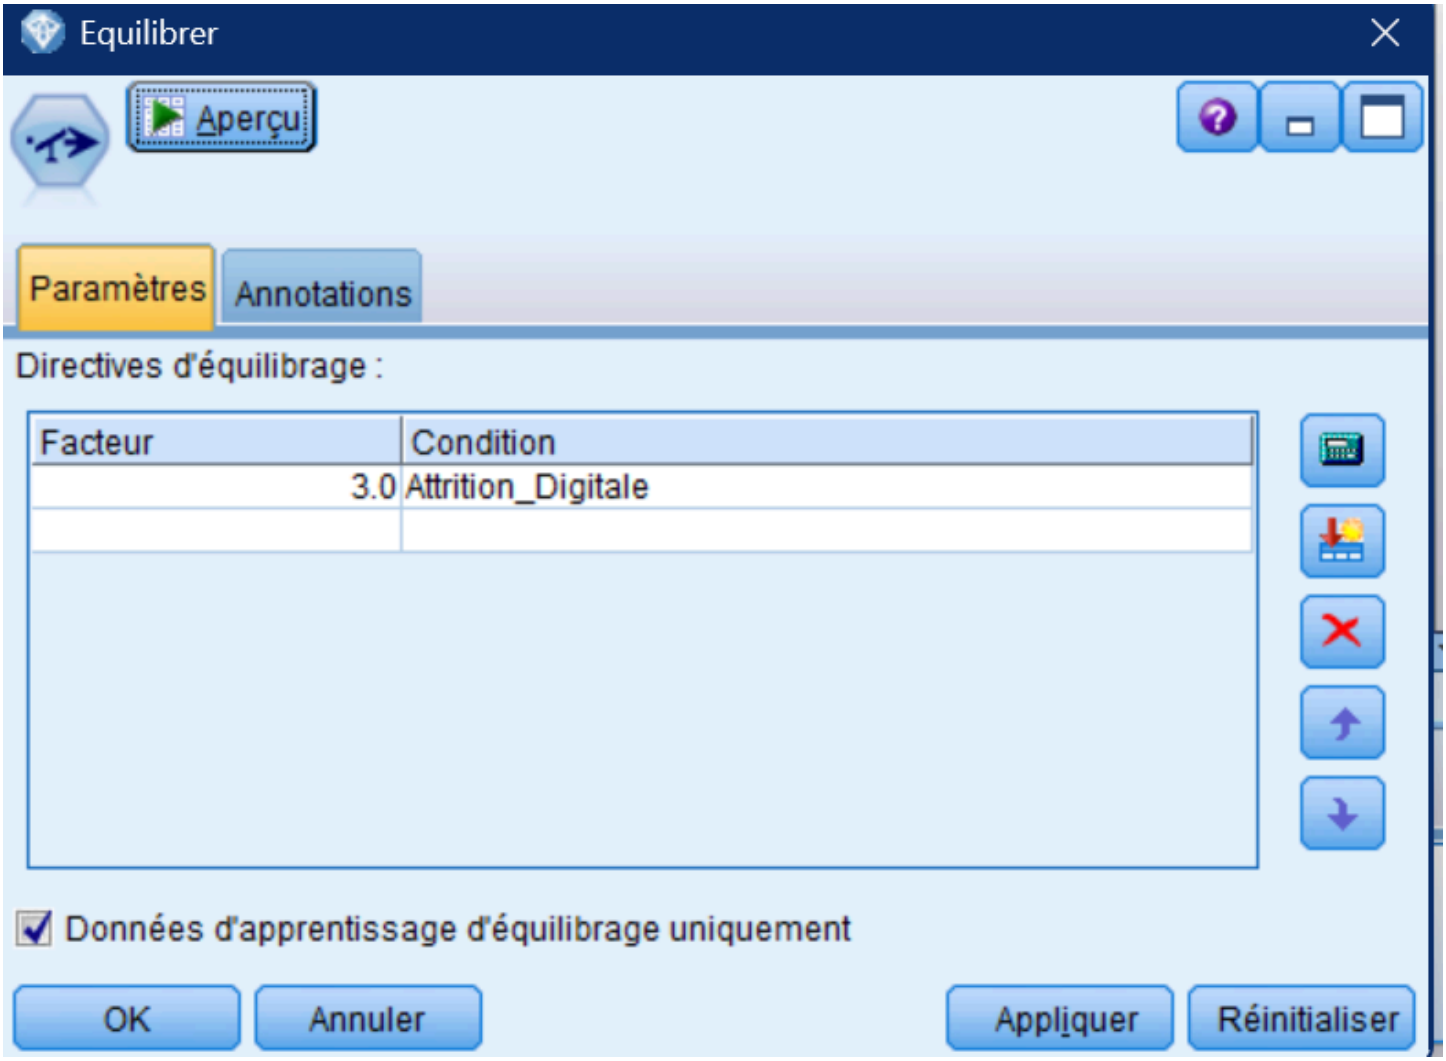
- environ **75,4 %** de clients non attritionnistes ;
- environ **24,6 %** de clients en attrition.

Ce déséquilibre peut biaiser l'apprentissage des modèles, en les poussant à privilégier la classe majoritaire.

Un modèle pourrait alors prédire massivement "Non" et obtenir une bonne accuracy tout en ratant les clients réellement à risque. Statistiquement flatteur, commercialement désastreux.

4. Équilibrage des classes

Afin d'améliorer la détection des clients en attrition, une technique de **sur-échantillonnage (oversampling)** a été appliquée sur la classe minoritaire.



Dans SPSS Modeler, un nœud d'équilibrage a été utilisé afin d'augmenter artificiellement la représentation des cas "Oui" dans l'échantillon d'apprentissage.

Cette opération permet :

- de renforcer l'apprentissage des signaux associés à l'attrition ;
- d'améliorer le rappel (Recall) sur la classe minoritaire ;
- de limiter le biais vers la classe majoritaire.

5. Respect des bonnes pratiques méthodologiques

L’équilibrage n’a été appliqué **que sur l’échantillon d’apprentissage**.

L’échantillon de test a été conservé dans sa distribution réelle afin de mesurer les performances du modèle dans des conditions proches du contexte opérationnel.

Cette distinction est essentielle pour éviter une surestimation artificielle des performances.

6. Intérêt métier

Dans un contexte bancaire, détecter un client susceptible de partir est généralement plus important que maximiser uniquement la précision globale.

Le coût d’un faux négatif (client à risque non détecté) peut être supérieur au coût d’un faux positif (client contacté inutilement).

L’équilibrage permet donc d’orienter les modèles vers un objectif métier plus pertinent : identifier les clients réellement menacés d’attrition.

7. Conclusion

La phase de partitionnement et d’équilibrage constitue une étape fondamentale de la préparation des données.

Elle garantit une évaluation fiable des modèles tout en améliorant leur capacité à détecter la classe minoritaire.

Cette base méthodologique robuste permet ensuite de comparer objectivement les différents algorithmes de prédiction.

PARTIE 8 : MODÉLISATION PRÉDICTIVE ET COMPARAISON DES ALGORITHMES

1. Objectif de la modélisation

L’objectif de cette étape est de construire des modèles capables de prédire la variable cible **Attrition_Digitale**, c’est-à-dire d’identifier les clients présentant un risque de départ.

Cette phase permet de transformer les données préparées en un outil décisionnel exploitable par la banque.

Les modèles ont été comparés selon trois dimensions principales :

- la performance prédictive ;
- la capacité de généralisation ;
- l’interprétabilité métier.

2. Algorithmes évalués

Afin de garantir la robustesse des conclusions, sept techniques de classification supervisée appartenant à différentes familles d'algorithmes ont été testées dans SPSS Modeler.

Arbres de décision

- C5.0
- CHAID
- QUEST

Méthodes d'ensemble

- Arbres Aléatoires (Random Forest)

Modèles statistiques et probabilistes

- Régression Logistique
- Réseau Bayésien

Intelligence artificielle

- Réseau de Neurones

Cette diversité permet de confronter des approches linéaires, non linéaires et probabilistes afin de sélectionner la méthode la plus adaptée au contexte bancaire.

3. Critères d'évaluation

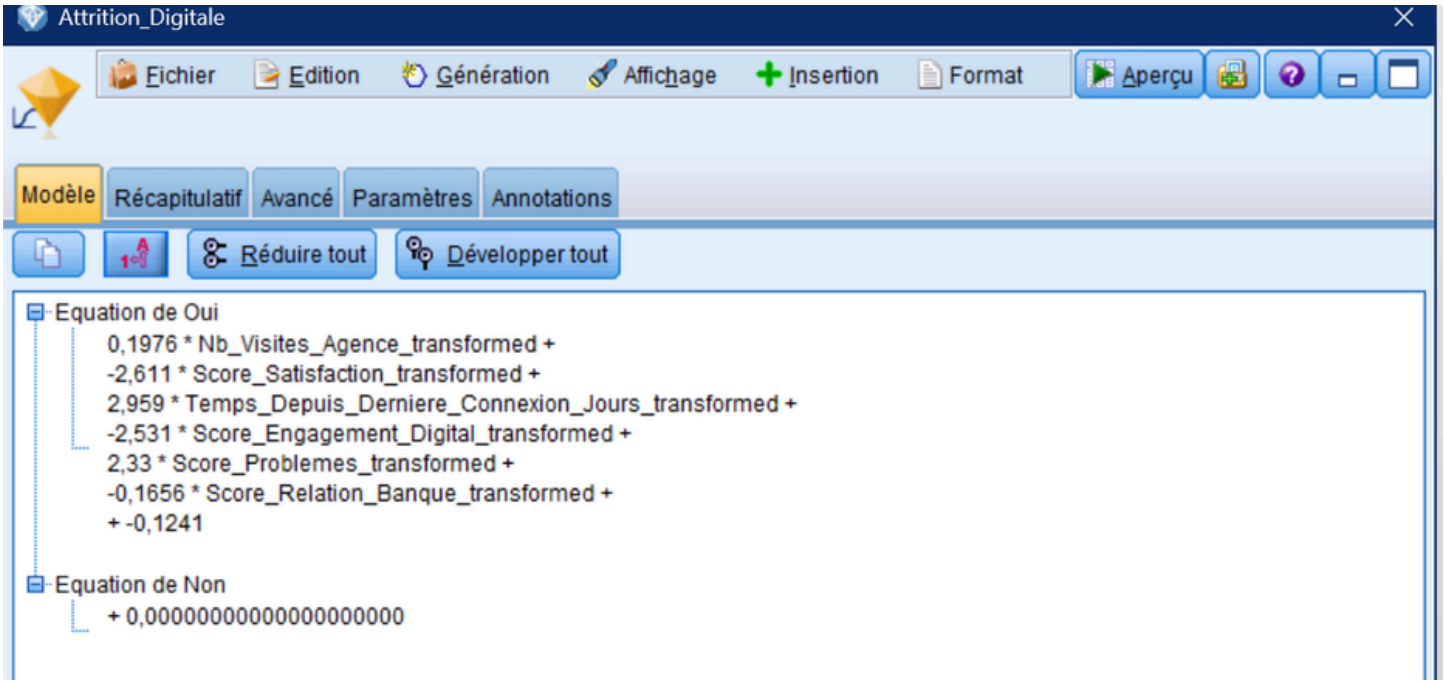
Les modèles ont été évalués à l'aide des indicateurs suivants :

- **Accuracy** : proportion globale de bonnes prédictions ;
- **AUC (Area Under the Curve)** : capacité du modèle à distinguer les clients à risque des autres ;
- **Recall (Rappel)** : capacité à détecter le maximum de cas réels d'attrition ;
- **Interprétabilité** : facilité de compréhension des résultats par les décideurs métier.

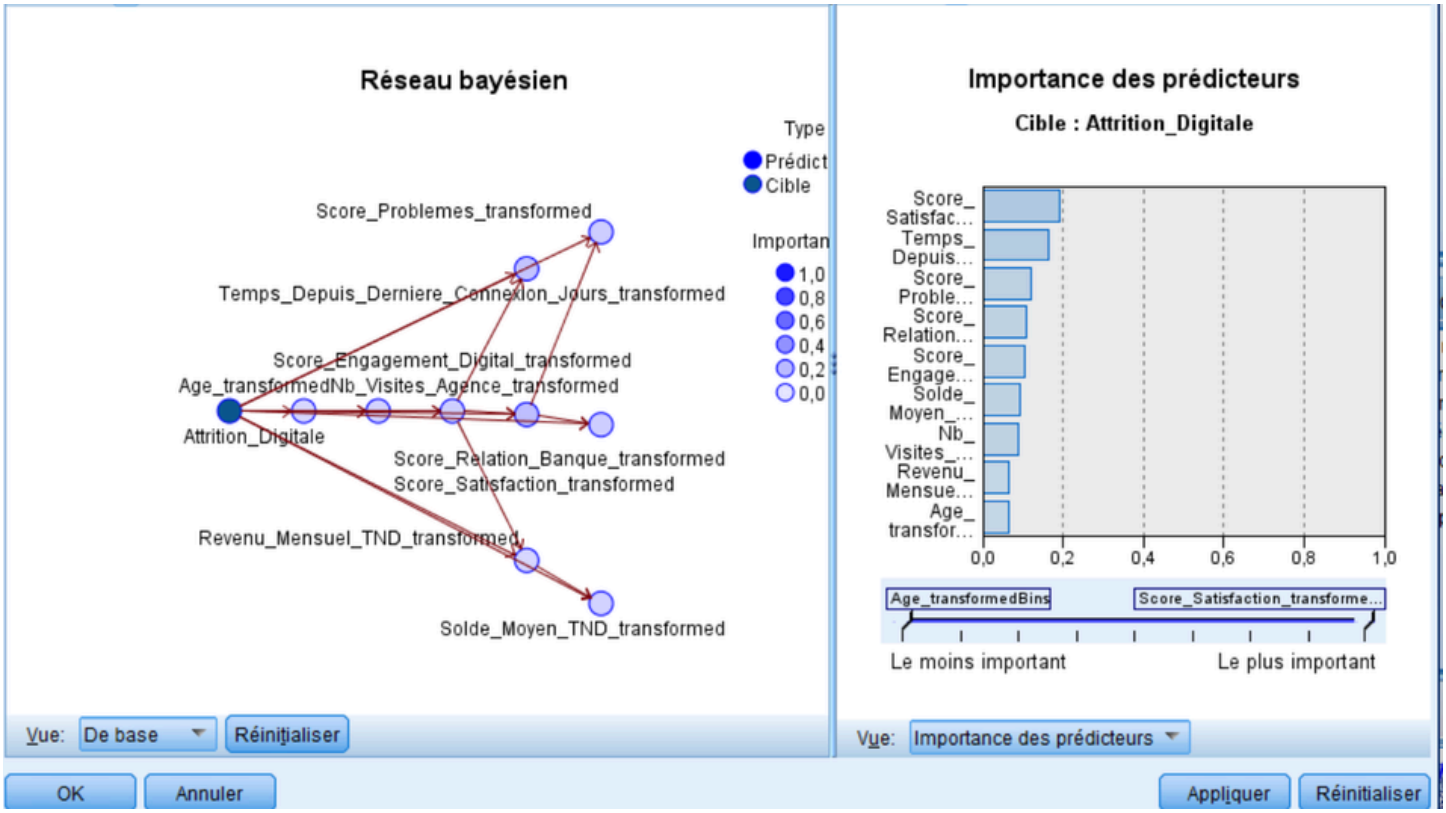
4. Résultats comparatifs et analyse

Les résultats obtenus à partir du nœud d'analyse montrent une performance globale satisfaisante, confirmant la qualité de la préparation des données.

- **C5.0** : meilleur modèle avec une Accuracy de **83,82 %** et un AUC de **0,893**.
- **CHAID** et **QUEST** : performances solides, respectivement autour de **81,56 %** et **79,90 %**, avec une excellente lisibilité sous forme d'arbres de décision.
- **Régression Logistique** : Accuracy de **80,55 %**, offrant une bonne stabilité ainsi qu'une interprétation claire des coefficients.



- **Réseau de Neurones** : Accuracy de **80,51 %**, avec de bonnes performances mais une faible explicabilité.
- **Réseau Bayésien** : Accuracy de **79,56 %**, apportant une lecture probabiliste intéressante du risque client.



Le Réseau Bayésien (visible sur l'image) ne se contente pas de classer les clients. Il cartographie les relations logiques entre toutes les variables. C'est une approche probabiliste car elle modélise l'incertitude : même si un client est satisfait, le réseau calcule s'il existe une probabilité de départ due à d'autres facteurs combinés, comme un long temps d'inactivité.

- **Arbres Aléatoires** : résultats satisfaisants et bonne robustesse, bien que légèrement inférieurs au modèle C5.0.

5. Focus sur le modèle retenu : C5.0

Le modèle **C5.0** est retenu pour un déploiement opérationnel pour trois raisons principales :

Performance prédictive

Il présente les meilleurs résultats globaux parmi les modèles testés.

Capacité de détection

Il réduit le nombre de faux négatifs, ce qui permet d'identifier efficacement les clients réellement susceptibles de quitter la banque.

Interprétabilité métier

Il génère des règles simples et directement exploitables, par exemple :

Si le score de satisfaction est faible et que le temps depuis la dernière connexion est élevé, alors le risque d'attrition augmente.

Ce type de résultat facilite la prise de décision commerciale, concept encore révolutionnaire dans certaines organisations.

6. Conclusion

L'évaluation comparative montre que le risque d'attrition dépend principalement du comportement digital et du niveau de satisfaction client.

Parmi les modèles testés, **C5.0** apparaît comme la solution la plus pertinente, en offrant le meilleur compromis entre précision statistique, capacité de détection et applicabilité opérationnelle.

Il constitue ainsi le modèle recommandé pour une utilisation concrète par les équipes bancaires.

PARTIE 9 : IDENTIFICATION DES VARIABLES CLÉS ET PROFIL DES CLIENTS À RISQUE

1. Objectif de l'analyse

Après la sélection du modèle prédictif le plus performant, cette étape vise à identifier les variables ayant la plus forte influence sur la prédiction de l'attrition digitale.

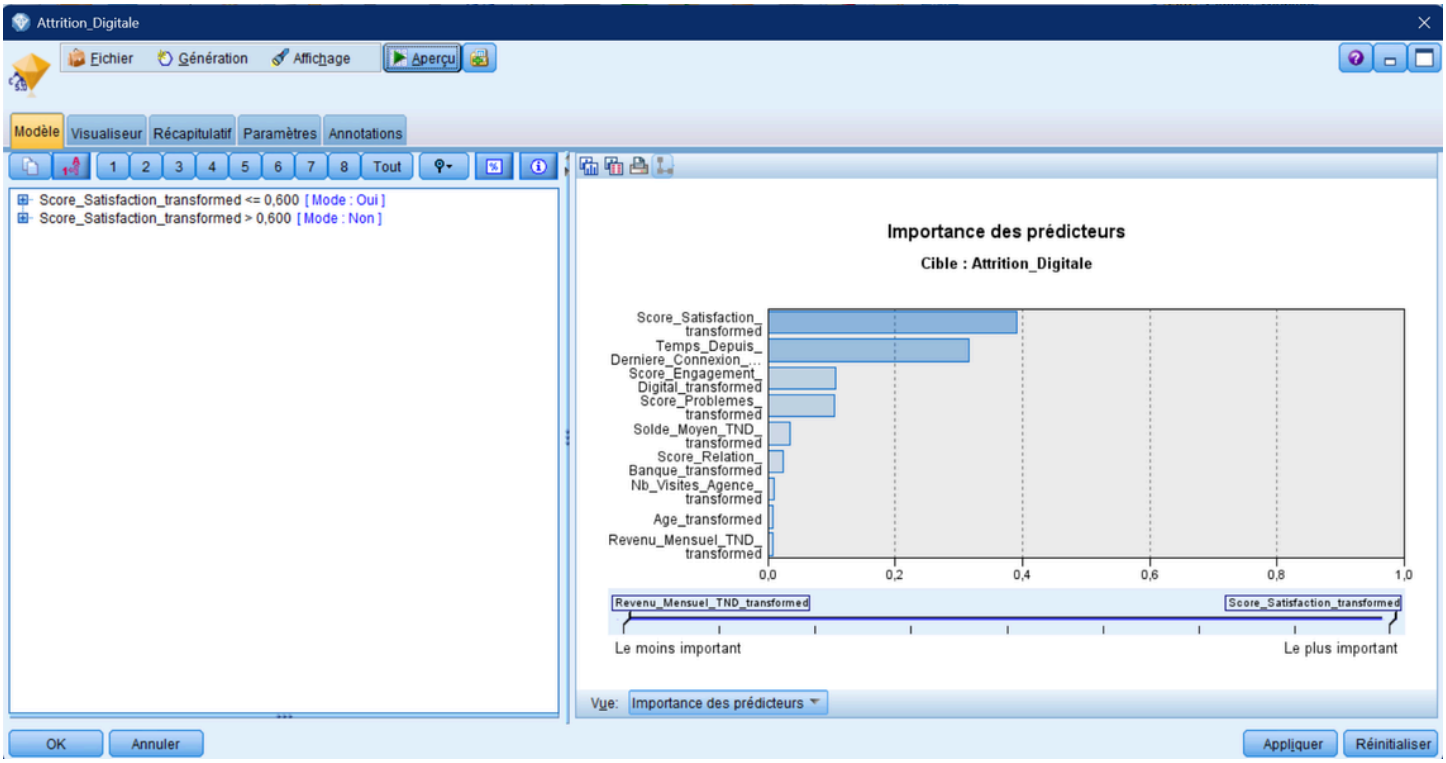
L'objectif est double :

- comprendre les facteurs déterminants du départ des clients ;
- établir le profil type des clients présentant un risque élevé d'attrition.

Cette analyse permet de transformer les résultats statistiques en leviers d'action concrets pour la banque.

2. Variables les plus influentes

L'étude de l'importance des prédicteurs, observée à travers les différents modèles testés, met en évidence une forte cohérence dans les résultats.



Les variables les plus influentes sont les suivantes :

Score_Satisfaction_transformed

Cette variable apparaît comme le principal facteur explicatif de l'attrition.

Un faible niveau de satisfaction constitue le signal le plus fort annonçant un risque de départ.

Temps_Depuis_Derniere_Connexion_Jours_transformed

Cette variable représente un indicateur comportemental majeur.

Plus le temps écoulé depuis la dernière connexion est élevé, plus la probabilité d'attrition augmente.

Score_Engagement_Digital_transformed

Un faible niveau d'engagement digital traduit une faible utilisation des services numériques et une relation moins ancrée avec la banque.

Score_Problemes_transformed

Les réclamations, incidents techniques ou difficultés rencontrées augmentent significativement le risque de départ.

3. Analyse métier des résultats

Les résultats montrent que l'attrition digitale dépend davantage du comportement client que de son profil socio-économique.

En effet, les variables démographiques telles que :

- l'âge ;
- le revenu ;
- la profession ;

présentent une influence plus faible que :

- la satisfaction ;
- l'usage digital ;
- la fréquence de connexion ;
- les problèmes rencontrés.

Autrement dit, un client quitte rarement sa banque parce qu'il vieillit. Il part surtout parce qu'il en a assez.

4. Profil type du client à risque élevé

L'analyse des règles issues du modèle C5.0 permet de dresser le profil du client présentant un risque élevé d'attrition.

Ce client présente généralement les caractéristiques suivantes :

- faible score de satisfaction ;
- espacement important entre les connexions ;
- faible engagement digital ;
- score de problèmes élevé ;
- diminution de l'activité bancaire digitale.

Il s'agit souvent d'un client en phase de désengagement progressif.

5. Profil du client fidèle et stable

À l'inverse, le client présentant un faible risque d'attrition se caractérise par :

- un niveau de satisfaction élevé ;
- des connexions régulières ;
- un usage actif des services digitaux ;

- peu de réclamations ;
- une relation bancaire stable.

Ce profil représente la clientèle la plus résiliente et la plus facile à fidéliser, ce qui est pratique pour tout le monde.

6. Intérêt opérationnel

L'identification des variables clés permet à la banque de mettre en place un système d'alerte précoce.

Par exemple :

- baisse de satisfaction ;
- chute de fréquence de connexion ;
- augmentation des incidents ;
- baisse de l'engagement digital.

Ces signaux peuvent déclencher automatiquement des actions de rétention ciblées.

7. Conclusion

L'analyse des variables influentes confirme que l'attrition digitale repose principalement sur trois dimensions :

- la satisfaction client ;
- l'assiduité d'utilisation ;
- l'engagement digital.

Le client à risque n'est donc pas défini par son statut social, mais par la dégradation progressive de son expérience bancaire.

PARTIE 10 : CROISEMENT DU SCORING PRÉDICTIF ET DE LA SEGMENTATION CLIENT

1. Objectif de l'analyse

L'objectif de cette étape est de combiner les résultats issus de la segmentation par clustering avec ceux du modèle prédictif d'attrition.

La segmentation permet d'identifier **qui sont les clients**, tandis que le scoring prédictif permet de déterminer **quels clients présentent un risque de départ**.

Le croisement de ces deux approches offre une vision plus stratégique de la clientèle et facilite la mise en place d'actions ciblées.

2. Principe du croisement

Chaque client appartient à un segment issu du clustering (K-Means) et dispose également d'un score de risque calculé par le modèle prédictif C5.0.

Cette double lecture permet de distinguer :

- les segments fortement exposés à l'attrition ;
- les segments stables ;
- les segments nécessitant un accompagnement spécifique ;
- les clients prioritaires à traiter.

Autrement dit, on ne se contente plus de savoir qu'un client va partir, on comprend aussi dans quel type de population il se situe.

3. Analyse des résultats par segment

3.1 Segment des clients premium en rupture

Ce segment regroupe des clients à forte valeur financière, fortement digitalisés mais peu satisfaits.

Le scoring montre que ce groupe présente le niveau de risque d'attrition le plus élevé.

Ces clients constituent la priorité absolue des actions de rétention, car leur départ représente une perte économique importante.

3.2 Segment des clients autonomes et satisfaits

Ce segment se compose de clients utilisant régulièrement les services digitaux, peu dépendants des agences et globalement satisfaits.

Le modèle prédictif attribue à ce groupe un faible niveau de risque.

Il s'agit du segment le plus stable, à maintenir par des actions de fidélisation classiques.

3.3 Segment des clients traditionnels de proximité

Ce segment regroupe des clients plus attachés à la relation en agence et moins engagés digitalement.

Le scoring y indique un niveau de risque intermédiaire.

Ces clients nécessitent principalement un accompagnement progressif vers les services digitaux et une attention sur la qualité du service physique.

4. Intérêt métier du croisement

Le croisement entre segmentation et scoring permet d'adapter les stratégies selon la nature du risque.

Par exemple :

- un client premium à risque nécessite une intervention rapide et personnalisée ;
- un client peu actif digitalement nécessite une campagne de réengagement ;
- un client fidèle à faible risque relève d'une simple stratégie de maintien.

Cette approche évite de traiter tous les clients à risque de la même manière, ce qui reste malheureusement une tentation administrative universelle.

5. Priorisation des actions

Grâce à cette analyse combinée, la banque peut hiérarchiser ses actions selon trois niveaux :

Priorité élevée

Clients à forte valeur appartenant à un segment instable et présentant un score de risque élevé.

Priorité moyenne

Clients à risque modéré ou en baisse d'engagement progressif.

Priorité faible

Clients satisfaits et peu exposés à l'attrition.

6. Conclusion

Le croisement du scoring prédictif et de la segmentation client constitue un levier stratégique majeur.

Il permet de passer d'une simple prédiction du départ à une compréhension fine des profils concernés.

Cette démarche améliore l'efficacité des campagnes de fidélisation en orientant les ressources vers les clients les plus sensibles et les plus rentables.

PARTIE 11 : RECOMMANDATIONS STRATÉGIQUES ET PLAN D'ACTION

1. Objectif de cette étape

À partir des résultats obtenus lors de la segmentation et de la modélisation prédictive, cette étape vise à proposer des recommandations concrètes permettant de réduire l'attrition digitale

et d’améliorer la fidélisation de la clientèle.

L’objectif final d’un modèle prédictif n’est pas de produire de jolis indicateurs, mais d’aider à prendre de meilleures décisions. Idée encore parfois controversée.

2. Renforcement de la satisfaction client

L’analyse a montré que le score de satisfaction constitue le facteur le plus influent dans la prédiction de l’attrition.

Il est donc recommandé de mettre en place un dispositif de suivi continu de la satisfaction reposant sur :

- enquêtes de satisfaction périodiques ;
- traitement rapide des réclamations ;
- suivi personnalisé des clients insatisfaits ;
- amélioration continue des parcours digitaux.

Une baisse durable de satisfaction doit être considérée comme un signal d’alerte prioritaire.

3. Réduction des incidents et amélioration de l’expérience digitale

Les problèmes techniques et incidents de connexion augmentent significativement le risque de départ.

Les actions recommandées sont :

- amélioration de la stabilité des plateformes web et mobile ;
- réduction des temps d’indisponibilité ;
- assistance technique réactive ;
- communication proactive lors d’incidents majeurs.

L’expérience utilisateur reste souvent plus persuasive que n’importe quelle campagne marketing.

4. Programme de réengagement digital

Les clients présentant une baisse de fréquence de connexion ou un faible engagement digital doivent faire l’objet d’actions spécifiques.

Il est recommandé de mettre en place :

- notifications personnalisées ;
- e-mails ciblés ;
- mise en avant des nouvelles fonctionnalités ;
- offres promotionnelles liées à l’usage digital ;

- accompagnement à distance.

L’objectif est de recréer une habitude d’utilisation régulière des services numériques.

5. Traitement différencié selon les segments clients

La segmentation réalisée permet d’adapter les actions selon les profils identifiés.

Clients premium en rupture

- prise de contact prioritaire ;
- conseiller dédié ;
- résolution rapide des irritants ;
- offres de fidélisation spécifiques.

Clients autonomes et satisfaits

- maintien de la qualité de service ;
- programmes de fidélité ;
- valorisation des usages digitaux.

Clients traditionnels de proximité

- accompagnement progressif vers le digital ;
- maintien du lien humain en agence ;
- assistance personnalisée.

Traiter tout le monde pareil est confortable, mais rarement intelligent.

6. Intégration du scoring dans la gestion commerciale

Le modèle prédictif C5.0 peut être intégré aux outils internes afin d’attribuer à chaque client un score de risque actualisé régulièrement.

Ce score permettrait :

- d’identifier les clients prioritaires ;
- de déclencher automatiquement des actions commerciales ;
- de suivre l’évolution du risque dans le temps ;
- d’optimiser les ressources des équipes commerciales.

7. Recommandation finale

Il est recommandé de déployer le modèle C5.0 comme outil d’aide à la décision, en l’associant à une stratégie relationnelle structurée.

Le modèle doit être utilisé non comme un simple indicateur statistique, mais comme un levier opérationnel au service de la fidélisation.

8. Conclusion

Les résultats obtenus montrent que l'attrition digitale peut être anticipée et réduite grâce à une approche combinant :

- analyse prédictive ;
- segmentation client ;
- amélioration de la satisfaction ;
- personnalisation des actions commerciales.

La banque peut ainsi passer d'une logique réactive à une logique proactive de gestion de la relation client.

PARTIE 12 : QUESTIONS DE RÉFLEXION ET ANALYSE MÉTHODOLOGIQUE

1. Le modèle le plus précis est-il forcément le meilleur pour une banque ?

La réponse est non.

Dans un contexte bancaire, la performance d'un modèle ne peut pas être évaluée uniquement à travers l'Accuracy. En effet, cette métrique ne reflète pas le coût réel des erreurs.

Le coût d'un faux négatif (ne pas détecter un client qui part réellement) est généralement beaucoup plus élevé que celui d'un faux positif (contacter un client qui ne part pas).

Ainsi, un modèle légèrement moins précis mais avec un meilleur Recall et une bonne interprétabilité peut être plus pertinent qu'un modèle plus performant mais incompréhensible.

Dans un environnement métier, la capacité à agir sur les résultats est aussi importante que la performance statistique.

2. Quel est l'impact du déséquilibre de classes sur l'évaluation ?

Le déséquilibre de classes influence fortement les résultats des modèles.

Lorsqu'une classe est majoritaire, un modèle peut obtenir une bonne Accuracy simplement en prédisant la classe dominante, sans réellement apprendre à détecter la classe minoritaire.

Cela crée une illusion de performance.

C'est pour cette raison que des métriques complémentaires sont nécessaires, notamment :

- le Recall, pour mesurer la capacité à détecter la classe minoritaire ;

- l’AUC, pour évaluer la qualité globale de séparation entre les classes.

Sans traitement du déséquilibre, les modèles risquent d’être biaisés et peu utiles en pratique.

3. Pourquoi la satisfaction et les incidents influencent-ils fortement l’attrition ?

La satisfaction client est un indicateur central de la relation entre le client et la banque.

Un niveau de satisfaction faible traduit une dégradation de l’expérience client, ce qui augmente fortement la probabilité de départ.

Les incidents et réclamations jouent souvent un rôle de déclencheur. Ils représentent des points de friction qui accélèrent le processus de désengagement.

Ainsi, l’attrition est rarement brutale : elle résulte généralement d’une accumulation de signaux négatifs.

4. Quelle différence entre un client à risque et un client anormal ?

Un client à risque est un client dont le comportement est similaire à celui des clients ayant déjà quitté la banque. Il est identifié par un modèle de scoring d’attrition.

Un client anormal, en revanche, présente un comportement atypique par rapport à la population générale, sans lien direct avec une intention de départ.

Les anomalies relèvent plutôt de la détection d’outliers, tandis que le risque d’attrition relève de la modélisation prédictive.

5. Quel algorithme recommander pour un usage opérationnel ?

Le modèle C5.0 est le plus adapté pour un usage opérationnel en banque.

Il combine trois avantages majeurs :

- une bonne performance prédictive ;
- une capacité élevée de détection des clients à risque ;
- une interprétabilité forte grâce à ses règles décisionnelles.

Dans un contexte métier, cette transparence est essentielle pour permettre aux équipes commerciales de comprendre et d’exploiter les résultats du modèle.

Conclusion des questions de réflexion

Ces éléments montrent que la modélisation prédictive ne doit pas être évaluée uniquement sur des critères statistiques, mais également sur sa capacité à répondre à des enjeux métier concrets tels que la prise de décision, la compréhension des résultats et l'efficacité opérationnelle.